TAIR-WM：基于 Exact-DDIM 反演与任务感知统计评分的免训练水印检测框架

工作初稿；标注的实验结果待补。

摘要

频域生成式水印通过恢复结构化初始噪声验证图像来源并识别注册密钥。几何变换会同时干扰特征恢复与模板匹配。本文提出免训练检测框架 *TAIR-WM*，包含三个技术层面：残差引导的 *Exact-DDIM* 将迭代反演细化适配到 *HSQR* 检测，结合有限评估预算、停止阈值与逐图像最佳候选保留；协方差感知验证对正确密钥特征残差进行均值中心化，并以收缩协方差白化后的距离评分；任务感知双评分共享恢复特征，由外部任务类型选择 *Mahalanobis* 验证或 *Complex-L1* 识别。神经网络权重保持固定，残差统计量离线拟合。在十二个非零双线性旋转角度上，相对于同家族的 *DDIM/Complex-L1* 基线，组合验证配置将 *FPR* 低于 *1%* 时的平均 *TPR* 从 *G0* 的 *3.99%* 提升至 *14.36%*，从 *G1* 的 *4.06%* 提升至 *15.53%*；平均 *AUC* 分别为 *0.8076* 和 *0.8075*。同家族模块对照、完整旋转曲线与冻结阈值结果支持该验证设计。身份识别单独评估，在旋转条件下仍然较弱。本文已有各分支的独立测量，集成任务路由结果仍待补充。

1. 引言

生成图像的来源信息为内容归属核验与传播追踪提供依据，因而需要在编辑和传播后仍可验证。生成式水印在合成过程中嵌入来源标记，并通过注册密钥进行后续检验 [5, 10]。漏检会使含水印图像失去来源关联，误报则会将无关图像关联到某个来源。因此，检测器需要在较低误报率下检出经过处理的水印图像。几何变换会改变恢复水印所需的空间对应关系，使这一目标尤其具有挑战性。

频域生成式水印将结构化图案嵌入扩散初始噪声，再通过图像反演恢复水印。Tree-Ring 建立了这一技术路线 [10]。SFWMark 进一步利用 Hermitian 对称嵌入保持傅里叶完整性，并通过中心感知布局增强抗裁剪能力 [5]。这些进展改善了嵌入表示，但编辑后的图像能否被可靠检出，还取决于检测端如何恢复和比较该表示。在 SFWMark 的 HSQR 变体中，检测器依次完成图像编码、DDIM 反演和基于 Complex-L1 的密钥模板匹配。

旋转同时暴露了这两个环节的困难。在有限画布上，旋转会改变频率坐标，并引入插值误差和边界信息损失。DDIM 反演在恢复初始潜变量时还会带来近似误差 [3, 9]，使得即便部分水印结构仍然存在，恢复系数也可能偏离密钥模板。最终残差混合了几何失真以及编码、反演的影响。Complex-L1 对各系数的偏差采用相同权重 [5]，没有描述残差的系统偏移，也没有区分不同方向的波动大小及其相关性。因此，改善反演步的一致性之后，仍需解决如何解释剩余残差的问题。

检测任务的目标进一步决定了残差评分应衡量什么。验证任务判断图像是否包含某个指定密钥，识别任务则对多个候选密钥进行排序。原始 SFWMark 检测器对两者均使用 Complex-L1 [5]。然而，判断残差是否符合正确密钥的统计分布，与比较不同模板之间的相对相似性，是两种不同的判别需求。适合验证的评分并不必然适合识别。由此，我们需要将更一致的特征恢复、残差统计建模和与任务目标相匹配的决策规则结合起来。

基于这一思路，我们提出免训练检测器 TAIR-WM，保留 HSQR 嵌入方式。神经网络权重保持固定，残差统计量通过离线拟合获得，验证或识别任务由调用方指定。三项技术贡献分别针对上述困难展开：

1. **残差引导的 Exact-DDIM 反演。**将 Exact-DPM 的前向步修正原理 [3] 适配于 HSQR 恢复，从 DDIM 初始化出发，根据局部重建残差修正候选，并设置有限评估预算和残差停止条件。逐图像保留已评估的最佳候选，使局部残差不高于初始化。
2. **协方差感知的水印验证。**利用正确密钥特征残

差的均值和 Ledoit–Wolf 收缩协方差 [4] 建立统计模型，通过 Mahalanobis 评分在考虑系统偏移与相关波动后判断残差兼容性。

3. **任务感知双评分检测。**在共享恢复特征上定义与任务对应的决策：指定密钥验证使用 Mahalanobis 评分，候选密钥识别使用 Complex-L1 匹配，使验证分支利用拟合的残差统计，同时为识别保留直接模板排序。

实验表明，该设计改善了旋转条件下的水印验证。在十二种非零角度的双线性旋转条件上，Exact-DDIM 与 Mahalanobis 的组合使 FPR 低于 1% 时的平均 TPR 在配置家族 G0 中由 3.99% 提升至 14.36%，在 G1 中由 4.06% 提升至 15.53%，比较对象均为各自家族的 DDIM 与 Complex-L1 基线。这意味着在相同误报约束下，平均检出率分别提高了 10.37 和 11.47 个百分点。模块对比进一步显示，反演修正的收益取决于评分方式，支持将特征恢复与验证评分配合设计。独立的识别测试表明，在原有十二条件测试集上，Complex-L1 优于 Mahalanobis，但旋转条件下的识别能力仍然较弱。目前已有任务分支的独立实验，任务路由的集成评估仍待完成。

2. 相关工作

生成式频域水印。 潜扩散模型允许在解码前嵌入水印 [6]。Tree-Ring 在初始噪声中嵌入傅里叶结构并通过反演检测 [10]。SFWMark 利用 Hermitian 对称性和中心嵌入保持频域完整性 [5]。TAIR-WM 沿用 HSQR 嵌入与特征提取，调整恢复和判别评分。

任务目标与几何鲁棒性。 RingID 研究二元检测、多密钥识别以及旋转下的离散傅里叶模式 [1]。SynTag 结合同步特征、学习式预测与几何校正 [2]。原始 SFWMark 已区分验证与识别，二者均采用 Complex-L1 [5]。因此，任务区分本身并非本文首创。本文为两类任务配置不同残差度量及输出规则，不引入角度估计或配准。

扩散反演。 DDIM 提供确定性采样及实用反演路径 [9]。Exact-DPM 将反演步视为隐式问题，研究前向步和梯度细化，并包含水印应用 [3]。GNRI 使用引导式 Newton–Raphson 迭代 [7]；FARI 研究结合对抗适配的鲁棒单步反演 [11]。本文将前向步机制用于 HSQR 检测中的一阶 DDIM。残差更新沿用已有方法；有限预算下的候选保留、残差评分及任务决策共同构成当前检测配置。

统计评分与辅助特征调制。 Ledoit–Wolf 收缩通过组合样本协方差和缩放单位矩阵，稳定高维协方差估计 [4]。本文将该估计器用于正确密钥水印残差。FreeU 对扩散 U-Net 的主干特征缩放，并调制跳跃连接特征的低频分量 [8]。项目在 G1 的生成和反演阶段均调用已有 FreeU 功能，没有加入水印条件化的新机制。因此，FreeU 保持辅助配置地位，不单列为技术贡献。

3. 方法

3.1. 问题定义与框架概述

设 x 为待检测图像，$\mathcal{K}$ 为注册密钥集合。验证检验调用方指定的密钥 k；识别从给定候选中选择密钥。记任务 $q \in \{\mathrm{V}, \mathrm{I}\}$。本文保留 HSQR 嵌入，共享 VAE 编码器 E、扩散反演 I 和傅里叶特征映射 Φ：

$$z_0 = E(x), \quad \widehat{z}_T = I(z_0), \quad f = \Phi(\widehat{z}_T). \tag{1}$$

其中，E 包含基础模型的潜变量缩放，$\widehat{z}_T$ 为恢复的初始噪声表示。图 1 展示三个技术环节。若同时请求两类任务，可复用恢复结果。

在中心感知配置中，Φ 截取潜变量中央 44×44 区域，执行移位二维 FFT，并从索引为 3 的通道选择 42×21 个复数系数。将其展平为 $c \in \mathbb{C}^m$，其中 $m = 882$，则

$$f = [\mathrm{Re}(c)^\top, \mathrm{Im}(c)^\top]^\top \in \mathbb{R}^p, \quad p = 2m = 1764. \tag{2}$$

密钥模板 w_k 使用相同排列。其实部和虚部来自 QR 图案的两个半区，参考值为 ±45，沿用原有检测器。对 $r_k = f - w_k$，验证衡量其与正确密钥残差分布的兼容程度；识别则比较 $\mathcal{K}$ 内各模板距离。

3.2. 残差引导的 Exact-DDIM 反演

局部一致性目标。 对于相邻扩散时刻 $t > s$，记确定性 DDIM 去噪步为 $D_{t\to s}$。在噪声预测表示下，

$$\begin{aligned} \widehat{z}_0(z_t) &= \frac{z_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(z_t, t)}{\sqrt{\bar{\alpha}_t}}, \\ D_{t\to s}(z_t) &= \sqrt{\bar{\alpha}_s}\,\widehat{z}_0(z_t) + \sqrt{1-\bar{\alpha}_s}\,\epsilon_\theta(z_t, t). \end{aligned} \tag{3}$$

实现采用基础调度器的系数与参数化。网络预测依赖未知的 z_t，因此反演是隐式问题。DDIM 反演

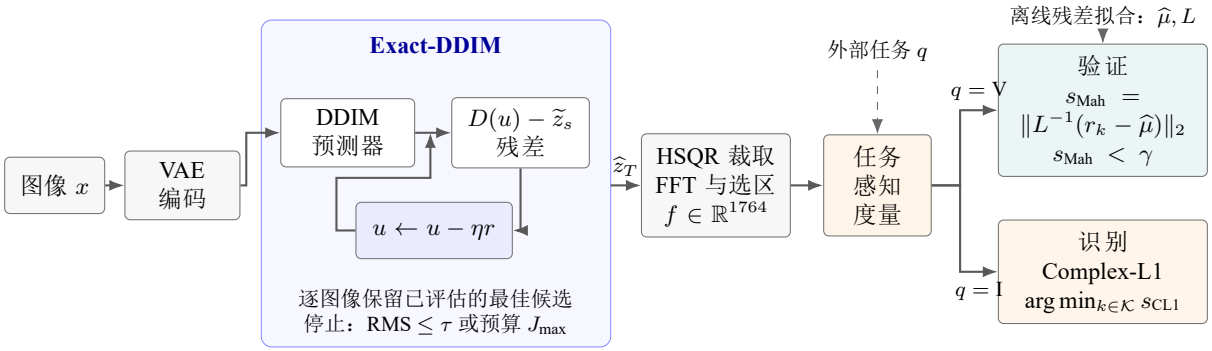


图 1. TAIR-WM 检测框架。残差引导的 Exact-DDIM 提供共享 HSQR 特征；协方差感知验证对指定密钥评分；外部任务选择该分支或 Complex-L1 识别。虚线表示离线统计量或调用方控制，实线表示推理数据流。三项贡献分别对应特征恢复、验证建模与任务决策，不引入学习式路由器。

给出近似解，但其去噪结果未必重建当前低噪声目标 $\widetilde{z}_s$。我们以

$$\mathcal{L}_t(z) = \frac{1}{d}\|D_{t\to s}(z) - \widetilde{z}_s\|_2^2. \tag{4}$$

衡量差异，其中 d 为每幅图像的潜变量元素数。细化循环内目标保持固定，无需已知真实初始噪声。

残差修正。 使用普通反演预测器初始化，并评估去噪重建：

$$z_t^{(0)} = I_{s\to t}^{\mathrm{DDIM}}(\widetilde{z}_s), \quad r_t^{(j)} = D_{t\to s}(z_t^{(j)}) - \widetilde{z}_s. \tag{5}$$

前向步修正为

$$z_t^{(j+1)} = z_t^{(j)} - \eta r_t^{(j)}. \tag{6}$$

这是 Exact-DPM 的前向步机制 [3] 在一阶 DDIM 检测器中的适配。更新直接减去潜变量重建残差，无需对去噪器求导；它并非对式 (4) 执行梯度下降，后者需要去噪映射的 Jacobian。

当前配置为 $\eta = 0.5$，每步最多评估 $J_{\max} = 5$ 个候选，容差 $\tau = 10^{-5}$。调度器的随机噪声参数为零。所选候选作为下一反演步的目标。

停止与逐图像保留。 当批内最大残差 RMS 不超过 τ，或评估预算耗尽时，细化终止。使用最大值要求每幅图像均满足容差，避免批平均误差较小却掩盖个别较大残差。

更新不一定单调改善。对每幅图像 b，保留已评估 MSE 最小的候选：

$$j_b^\star = \arg\min_{j\in\mathcal{J}_b} \mathcal{L}_t(z_{t,b}^{(j)}), \quad \widetilde{z}_{t,b} = z_{t,b}^{(j_b^\star)}. \tag{7}$$

评估集合 $\mathcal{J}_b$ 包含初始化。未经评估的最终更新不参与选择。对有限的已评估损失，直接得到

$$\mathcal{L}_t(\widetilde{z}_{t,b}) \le \mathcal{L}_t(z_{t,b}^{(0)}). \tag{8}$$

该性质仅针对单步固定目标，不保证严格改善、全局收敛或恢复旋转中丢失的信息。Exact-DDIM 表示所采用的细化方法类别，不代表有限预算下精确恢复。算法 1 给出候选评估及任务决策流程。

3.3. 协方差感知的水印验证

正确密钥残差模型。 对拟合特征 f_i 和已知正确模板 w_{k_i}，令 $r_i = f_i - w_{k_i}$。均值描述系统偏移，协方差描述各频率位置及实部、虚部之间的变化与相关性：

$$\widehat{\mu} = \frac{1}{n}\sum_{i=1}^{n} r_i, \quad S = \frac{1}{n}\sum_{i=1}^{n}(r_i - \widehat{\mu})(r_i - \widehat{\mu})^\top. \tag{9}$$

恢复分布未必以模板为中心。几何扰动也可能使多个系数共同变化，因此将各残差视为等尺度、相互独立的误差并不充分。

拟合样本数 $n = 1024$ 小于特征维度 $p = 1764$，样本协方差因而秩亏。采用 Ledoit–Wolf 收缩 [4]：

$$\begin{aligned} \widehat{\Sigma} &= (1-\lambda)S + \lambda a I, \quad a = \frac{\mathrm{tr}(S)}{p}, \\ \Sigma_{\mathrm{reg}} &= \widehat{\Sigma} + \varepsilon I. \end{aligned} \tag{10}$$

估计器依据拟合数据确定 λ；仅在 Cholesky 分解需要时添加非负抖动 ε。这些均为已有估计工具。本文的建模选择在于针对检测器的正确密钥残差拟合，并为不同反演配置分别估计统计量。

白化兼容性评分。 分解 $\Sigma_{\text{reg}} = LL^\top$，求解 $Lv_k = r_k - \widehat{\mu}$，定义

$$s_{\text{Mah}}(r_k) = \|v_k\|_2 = \sqrt{(r_k - \widehat{\mu})^\top \Sigma_{\text{reg}}^{-1}(r_k - \widehat{\mu})}. \tag{11}$$

实现使用三角方程求解而非显式构造逆矩阵。高方差方向权重较低，非对角项描述相关偏移。分数衡量观测残差与拟合正确密钥群体的兼容程度，并不假定水印与无水印图像均服从完整的高斯似然模型。

协方差权重能够适应拟合数据中反复出现的扰动，但作用取决于该分布。满秩白化是可逆变换，并不天然删除高频系数；后续范数才将向量压缩为标量。因此，密钥区分能力可能下降的解释涉及方向权重变化，而非已经证明某些频带被删除。这也促使我们将验证与密钥排序分开。

3.4. 任务感知双评分检测

验证将一个指定密钥与无水印情形区分，识别则对多个候选排序。本文的任务感知双评分规则，也称 Task-Aware Adaptive Metric，为

$$s_q(f, w_k) = \begin{cases} s_{\text{Mah}}(f - w_k), & q = \text{V}, \\ s_{\text{CL1}}(f, w_k), & q = \text{I}. \end{cases} \tag{12}$$

对复数系数 c_j 和模板系数 $u_{k,j}$，识别距离为

$$s_{\text{CL1}}(f, w_k) = \frac{1}{m}\sum_{j=1}^{m} |c_j - u_{k,j}|, \qquad |a + ib| = \sqrt{a^2 + b^2}. \tag{13}$$

Complex-L1 是复数模的平均值，不是实部和虚部绝对差的分别相加。它保留原检测器对各复数位置的等权处理。任务输出为

$$\begin{aligned} \widehat{y} &= \mathbf{1}[s_{\text{Mah}}(r_k) < \gamma] && (q = \text{V}), \\ \widehat{k} &= \arg\min_{k \in \mathcal{K}} s_{\text{CL1}}(f, w_k) && (q = \text{I}). \end{aligned} \tag{14}$$

阈值 γ 的标定独立于测试图像。识别属于闭集选择，不使用 γ 拒绝未知密钥。

该接口共享特征 f，将指定密钥的统计接受规则与候选密钥的直接排序分开。任务选择由外部控制，不使用学习式门控、攻击分类器或逐图像度量搜索。两个评分分支已有独立测量，集成执行结果仍为 [待补]。本文不声称所选识别分支在所有攻击下都优于其他度量。

算法 1 Exact-DDIM 与任务感知双评分

输入： 图像 x、任务 q、密钥或密钥集合、拟合统计量 $(\widehat{\mu}, L)$、阈值 γ

$z \leftarrow E(x)$
循环 按噪声递增顺序遍历反演步 (s, t) **执行**
  $\widetilde{z}_s \leftarrow z$；$u \leftarrow I_{s\to t}^{\text{DDIM}}(\widetilde{z}_s)$
  对每幅图像 b，令 $e_b^\star \leftarrow +\infty$
  循环 $j = 0, \ldots, J_{\max} - 1$ **执行**
    $r \leftarrow D_{t\to s}(u) - \widetilde{z}_s$
    对每个 b，计算 $e_b \leftarrow \text{mean}(r_b^2)$
    若 图像 b 满足 $e_b < e_b^\star$ **则**
      $u_b^\star \leftarrow u_b$；$e_b^\star \leftarrow e_b$
    结束条件
    若 $\max_b \sqrt{e_b} \le \tau$ **则**
      跳出循环
    结束条件
    $u \leftarrow u - \eta r$
  结束循环
  $z \leftarrow u^\star$
结束循环
$f \leftarrow \Phi(z)$
若 $q = \text{V}$ **则**
  $v \leftarrow L^{-1}(f - w_k - \widehat{\mu})$
  返回 $\mathbf{1}[\|v\|_2 < \gamma]$
否则
  返回 $\arg\min_{k\in\mathcal{K}} s_{\text{CL1}}(f, w_k)$
结束条件

3.5. 实现与计算成本

采用 Stable Diffusion 2.1 base，分辨率为 512×512。图像调整尺寸并映射到 $[-1, 1]$，使用 VAE 后验众数及潜变量缩放进行编码。反演采用 50 步、fp32、空提示词及零引导强度，神经网络权重固定。

每个反演步需要一次预测和最多五次去噪评估：

$$N_{\text{eval}} = T + \sum_{t=1}^{T} J_t \le T(1 + J_{\max}), \qquad T = 50, \quad J_{\max} = 5, \quad N_{\text{eval}} \le 300. \tag{15}$$

这表示模型评估预算，而非实测延迟倍数。最佳候选可在线维护，无需存储整条轨迹。离线统计拟合与矩阵分解不引入额外神经训练。完整协方差验证需要 $O(p^2)$ 三角求解及 $O(p^2)$ 统计量存储；对 K 个密钥，Complex-L1 识别为 $O(Km)$，可分块处理模板。任务选择仅增加条件分支。

统计量与阈值按配置分别拟合。对角评分使用相同拟合均值及收缩协方差的对角线，并设置数值下限。冻结阈值取 2000 个干净无水印标定距离的第 20 个顺序统计量，采用式 (14) 的严格小于判断。

G0 关闭 FreeU；G1 在生成和反演阶段均调用已有管线功能，参数为 $(s_1, s_2, b_1, b_2) = (0.9, 0.2, 1.4, 1.6)$。它改变预测和去噪评估所用 U-Net 的特征流，不引入密钥条件化模块，也不改变 HSQR 嵌入规则。内部特征的频域调制与直接编辑水印傅里叶模板是不同操作。

4. 实验

通过模块组合与任务对照评估三个技术层面。前者检验恢复与验证评分，后者检验两类决策规则的依据及边界。完整旋转曲线和冻结阈值揭示均值可能掩盖的失效条件，辅助配置用于补充解释。

4.1. 实验设置

使用已有 Q0–Q5 记录。Q0/Q1 属于 G0，Q3/Q4 属于 G1，每组将 DDIM 替换为 Exact-DDIM；Q2/Q5 是对应家族的 GNRI 配置。同家族比较保持生成池和 FreeU 设置一致。跨家族同时改变生成池与 FreeU 状态，无法单独归因于 FreeU。

拟合、标定、开发样本数分别为 1024、2000、400，测试使用 1000 对图像。每个条件包含 1000 幅带水印及 1000 幅对应无水印图像。拟合分为八组、每组 128 个样本：干净图像、JPEG、噪声、中心裁剪、随机裁剪，以及绝对角度为 5°、15°、30° 的旋转；各旋转组包含正负方向。因此，评估同时包含拟合覆盖角度与额外角度。

主要测试是在固定画布上执行双线性旋转：

$$\theta \in \{\pm 5, \pm 10, \pm 15, \pm 30, \pm 45, \pm 75\}^\circ.$$

旋转均值等权包含全部十二个非零角度。零度作为独立控制；最近邻旋转和正交旋转不计入该均值。曲线保留正负方向，因为两者表现未必相同。

报告 AUC，以及测试 ROC 上满足 FPR $< 1\%$ 的点中最大 TPR，使用负距离作为正类分数。1000 个负样本下最多允许九个误报。这不同于预先固定阈值：Frozen TPR/FPR 使用干净数据标定的阈值。AUC 与各比率按条件取均值，不将分数汇总后重新计算。所报结果为点估计，不提供置信区间或显著性结论。

身份识别准确率指在 2048 个密钥中选对密钥的比例。Original-12 汇总包含干净图像、亮度、对比度、JPEG、模糊、噪声、BM3D、两类 VAE、扩散再生成、中心裁剪及随机裁剪。任务对照保留全部十二个来源条件；主要验证场景仍为旋转。

4.2. 旋转下的主要结果

表 1 和图 2 给出主要结果。Exact-DDIM/Mahalanobis 在 G0 达到平均 AUC 0.8076、TPR 14.36%，在 G1 达到 AUC 0.8075、TPR 15.53%。按表中展示精度，相对于各自 DDIM/Complex-L1 基线，TPR 分别增加 10.37 和 11.47 个百分点。这是组合验证分支的增益，不能全部归于反演。

保持 Mahalanobis 时，DDIM 改为 Exact-DDIM 使 G1 在全部十二个角度上的 AUC 提高；TPR 在十个角度提高，-45° 不变，$+45^\circ$ 从 11.8% 降至 10.8%。G0 的 AUC 与 TPR 各在十一个角度提高，TPR 在 -75° 略降。完整 ROC 排序改善不要求每个工作点均改善。

大角度仍然困难。组合分支在 $+75^\circ$ 的 G0/G1 TPR 为 4.5%/4.9%，在 -75° 为 4.4%/3.7%。方法改变数值恢复和残差评分，没有对旋转模板执行对齐。

在 Mahalanobis 下，G0 Frozen TPR 从 4.50% 提高至 8.60%，Frozen FPR 从 0.25% 变为 0.35%；G1 TPR 从 5.38% 提高至 9.49%，FPR 从 0.31% 变为 0.38%。这说明攻击评估前固定阈值时也存在增益。不过，G1 Exact-DDIM/Mahalanobis 在 $+5^\circ$ 的 Frozen FPR 为 1.2%，说明干净标定不能保证每个攻击条件均满足名义误报目标。

4.3. 反演与评分消融

保持 Complex-L1，仅将 DDIM 替换为 Exact-DDIM，G0 平均 TPR 从 3.99% 变为 3.95%，G1 从 4.06% 变为 4.32%；AUC 分别从 0.6305 变为 0.6274、从 0.6299 变为 0.6279。使用原评分时，单独细化反演不能复现组合增益。

在 DDIM 下，Complex-L1 改为 Mahalanobis 后，G0/G1 TPR 提高至 10.20%/10.48%；随后使用 Exact-DDIM，进一步增加 4.16/5.05 个百分点。这些对照支持恢复与评分选择在经验上的互补性。定义

$$\begin{aligned}\Delta_{\text{int}} = (M_{\text{Exact,Mah}} - M_{\text{DDIM,Mah}}) \\ - (M_{\text{Exact,CL1}} - M_{\text{DDIM,CL1}}).\end{aligned} \tag{16}$$

其中 M 为旋转平均 TPR。按展示值计算，G0 为 4.20 个百分点，G1 为 4.79 个百分点。这只是描述性交互对照，并非因果分解或显著性检验：每种反演均重新拟合统计量，评分替换也同时改变中心化和协方差权重。

对 Exact-DDIM，G0 的 L2、对角评分 TPR 为 5.03%/7.52%，完整 Mahalanobis 为 14.36%；G1 分

表 1. 十二个非零双线性旋转角度的均值。AUC 无量纲，其余数值单位为百分比。每个家族四行构成两种反演与两种评分的交叉对照。冻结比率使用各配置在干净数据上标定的阈值。粗体标识组合验证配置，不表示每列最优。

家族	反演	评分	AUC	TPR (< 1%)	Frozen TPR	Frozen FPR
G0	DDIM	Complex-L1	0.6305	3.99	2.49	0.60
G0	Exact-DDIM	Complex-L1	0.6274	3.95	2.52	0.56
G0	DDIM	Mahalanobis	0.7892	10.20	4.50	0.25
G0	Exact-DDIM	Mahalanobis	**0.8076**	**14.36**	**8.60**	**0.35**
G1	DDIM	Complex-L1	0.6299	4.06	2.69	0.50
G1	Exact-DDIM	Complex-L1	0.6279	4.32	2.33	0.52
G1	DDIM	Mahalanobis	0.7878	10.48	5.38	0.31
G1	Exact-DDIM	Mahalanobis	**0.8075**	**15.53**	**9.49**	**0.38**

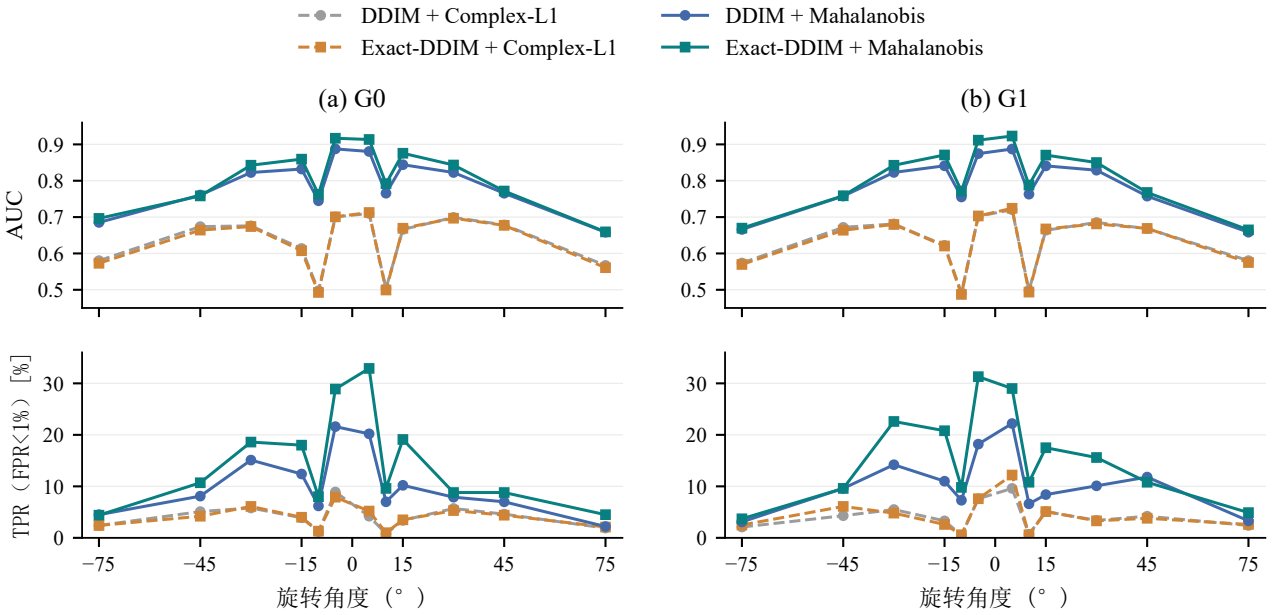


图 2. 全部十二个非零双线性旋转角度上的验证结果。上排为 AUC，下排为 FPR 低于 1% 时的 TPR；两列分别为 G0 和 G1。每个点均来自已有逐角度测量，连线仅便于阅读，不代表推断的中间测量或不确定性范围。保留全部角度，包括大角度失效条件。

别为 5.05%/8.26% 与 15.53%。对角和完整评分共享拟合均值及协方差估计，其差异用于检验当前实现中的非对角结构。L2 到对角评分还包含中心化和方向缩放变化，不能称为纯相关性消融。

4.4. 任务感知评分

表 2 区分两类任务目标。在 Exact-DDIM 下，Mahalanobis 的旋转验证优于 Complex-L1；在 Original-12 上，Complex-L1 识别准确率两个家族均为 98.73%，Mahalanobis 为 80.46%/80.45%。这些独立分支结果支持为指定密钥兼容性与多密钥排序采用不同评分。

Complex-L1 并非普遍最优。Original-12 上 L2 识别略高，为 98.80%/98.78%。本文保留原检测器的复数模规则作为明确的识别分支，不针对每种攻击单独挑选度量。

旋转识别仍然较弱：按来源精度，Complex-L1 两个家族均为 0.13%，Mahalanobis 为 0.09%/0.08%。Original-12 的准确率不能推及旋转图像，验证增益也不代表多密钥身份已经恢复。

末两行预留集成路由评估：需在相同请求和候选集合下，检验接口是否复现各独立分支的行为。应分别报告各任务指标，而非混合准确率。结果仍为 [待补]；独立分支均值不能充当集成路由的测量。

表 2. Exact-DDIM 下的分任务评分（G0/Q1、G1/Q4）。单位为百分比，识别候选数为 2048。CL1 和 Mah 分别表示 Complex-L1、Mahalanobis。集成任务路由仍待测量。

条件 / 指标	评分	G0	G1
旋转 / TPR	CL1	3.95	4.32
旋转 / TPR	Mah	14.36	15.53
Original-12 / ID	CL1	98.73	98.73
Original-12 / ID	L2	98.80	98.78
Original-12 / ID	Mah	80.46	80.45
旋转 / ID	CL1	0.13	0.13
旋转 / ID	Mah	0.09	0.08
路由 / 旋转 TPR	Mah	[待补]	[待补]
路由 / Original-12 ID	CL1	[待补]	[待补]

4.5. 辅助配置

GNRI [7] 配合 Mahalanobis 时，G0 AUC 为 0.7986、TPR 为 13.11%，G1 为 0.7978/13.72%，这些均值低于 Exact-DDIM。但 G0 GNRI Frozen TPR 为 9.23%，高于 8.60%，同时 Frozen FPR 为 0.46% 而非 0.35%，结论因评价端点而异。GNRI 使用两次内部迭代，Exact-DDIM 最多评估五个候选，因而不是等计算量比较。包含两个评分分支的同设备端到端延迟仍为 [待补]。

FreeU 同时改变 G1 生成和反演的 U-Net 特征流，因此可能影响生成信号及恢复残差分布，但尚未证实具体的水印频域效应。分别拟合统计量可以适应配置相关残差，却不构成新的 FreeU 协作机制。由于生成池与两个阶段的 FreeU 状态同时变化，G0/G1 对比既不能隔离 FreeU 效果，也不能隔离其与 Exact-DDIM、Mahalanobis 的交互。现有正式记录没有提供支撑这些结论所需的匹配、分阶段证据。

5. 讨论

不同技术环节的分工。 TAIR-WM 分别处理局部反演一致性、正确密钥残差兼容性与任务决策。最佳候选保留给出局部非增性质；协方差评分利用经验残差分布；任务接口为不同输出配置不同评分。本文不将残差更新或 Mahalanobis 数学工具宣称为原创，其 HSQR 适配与检测器职责划分构成实际贡献。

证据与边界。 完整旋转评估支持组合验证分支，但不能确定哪些频率方向主导增益。较低的大角度 TPR 和旋转识别准确率表明同步问题尚未解决。拟合采用指定扰动混合，不能证明对任意攻击分布均更优。本文未单独分析亮度和噪声条件。

集成路由、同设备延迟和隔离 FreeU 机制的实验仍未验证。未知密钥搜索还需要独立误报分析，因为同时检验多个密钥会改变决策事件。这些限制约束现有分支测量的解释范围。

6. 结论

TAIR-WM 保持 HSQR 嵌入与神经权重固定，将检测器划分为残差引导的 Exact-DDIM 反演、协方差感知水印验证、任务感知双评分检测三个环节。有限预算下的候选保留保证已评估局部一致性不劣于初始化。正确密钥残差白化使组合分支在两个家族的十二角度网格上获得更高的平均验证 AUC 与低误报 TPR。Complex-L1 提供单独评估的识别分支。完整模块对照、冻结阈值与分任务结果保留了证据边界：旋转识别仍然较弱，集成路由仍需测量。

参考文献

[1] Hai Ci, Pei Yang, Yiren Song, and Mike Zheng Shou. RingID: Rethinking tree-ring watermarking for enhanced multi-key identification. In *ECCV*, pages 338–354, 2024.

[2] Han Fang, Kejiang Chen, Zehua Ma, Jiajun Deng, Yicong Li, Weiming Zhang, and Ee-Chien Chang. SynTag: Enhancing the geometric robustness of inversion-based generative image watermarking. In *ICCV*, pages 15416–15425, 2025.

[3] Seongmin Hong, Kyeonghyun Lee, Suh Yoon Jeon, Hyewon Bae, and Se Young Chun. On exact inversion of DPM-solvers. In *CVPR*, pages 7069–7078, 2024.

[4] Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004.

[5] Sung Ju Lee and Nam Ik Cho. Semantic watermarking reinvented: Enhancing robustness and generation quality with fourier integrity. In *ICCV*, pages 18759–18769, 2025.

[6] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *CVPR*, pages 10684–10695, 2022.

[7] Dvir Samuel, Barak Meiri, Haggai Maron, Yoad Tewel, Nir Darshan, Shai Avidan, Gal Chechik, and Rami Ben-Ari. Lightning-fast image inversion and editing for text-to-image diffusion models. In *ICLR*, 2025.

[8] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. FreeU: Free lunch in diffusion U-Net. In *CVPR*, pages 4733–4743, 2024.

[9] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *ICLR*, 2021.

[10] Yuxin Wen, John Kirchenbauer, Jonas Geiping, and Tom Goldstein. Tree-rings watermarks: Invisible fingerprints for diffusion images. In *NeurIPS*, pages 58047–58063, 2023.

[11] Jindong Yang, Han Fang, Weiming Zhang, Nenghai Yu, and Kejiang Chen. FARI: Robust one-step inversion for watermarking in diffusion models. In *ICLR*, 2026.