TAIR-WM：基于反演精修与协方差感知评分的免训练水印验证框架

摘要

频域生成式水印通过反演恢复嵌入初始噪声的结构，以验证图像是否含有指定密钥的水印。旋转引入的几何失真与数值反演误差共同削弱了模板匹配。我们提出免训练验证框架 TAIR-WM，在保持 HSQR 嵌入规则不变的条件下，结合残差引导的 Exact-DDIM 精修与协方差感知评分。前者以局部去噪重建残差修正反演步，逐图像保留已评估的最佳候选；后者以正确密钥残差的均值和 Ledoit–Wolf 收缩协方差构建 Mahalanobis 距离。进一步采用已有的 FreeU 推理时特征调制，分析生成质量与水印验证的兼容性。在十个非零双线性旋转角度上，相对于同池 DDIM/Complex-L1，联合配置将 FPR 低于 1% 时的平均 TPR 从 G0 的 4.36% 提高至 16.34%，从 G1 的 4.42% 提高至 17.78%。含水印图像的 MUSIQ-AVA 与 LAION-Aes 平均分分别增加 0.0320 和 0.0165，CLIP 配对差值的 95% 区间包含零。结果支持所评估配置下的小幅美学收益与旋转验证改善，同时体现出统计评分在部分常规攻击下的性能代价。G1 在生成与反演阶段均启用 FreeU，跨池差异反映这两个阶段的组合变化。

1. 引言

生成图像在编辑与传播后仍需能够验证其来源。水印验证（Verification）判断图像是否包含指定密钥对应的水印；多密钥识别（Identification）则需在候选集合中确定其身份。我们聚焦前一任务，研究保持嵌入机制不变时，检测端的特征恢复与残差评分如何影响几何失真后的验证能力。

基于扩散反演的生成式水印将结构化图案嵌入初始噪声，再从生成图像中恢复该表示。Tree-Ring 建立了频域嵌入与反演检测的技术路线 [10]。SFWMark 利用 Hermitian 对称保持傅里叶完整性，并通过中心感知布局增强抗裁剪能力 [5]。在其 HSQR 配置中，图像依次经过 VAE 编码、DDIM 反演和 Complex-L1 模板匹配。这些步骤使检测能力同时受嵌入结构、反演误差和评分方式影响。

旋转会改变频率坐标，有限画布上的插值和边界截断还会造成信息损失。DDIM 的有限步近似进一步引入反演误差 [3, 9]，使恢复特征偏离密钥模板。Complex-L1 对各复数系数的偏差等权处理 [5]，没有描述残差的系统偏移及不同方向的相关波动。因此，更一致的数值反演需要与适合正确密钥残差分布的评分结合，才能将恢复结果用于验证。

我们将 Exact-DPM 的前向步修正原理 [3] 适配到一阶 DDIM 反演，以固定低噪声目标的局部重建残差指导有限步精修，并保留已评估候选中的逐图最优状态。随后，以正确密钥残差的均值与 Ledoit–Wolf 收缩协方差 [4] 构造 Mahalanobis 距离。该组合分别作用于特征恢复和统计判别；局部重建一致性并不消除旋转造成的几何信息损失。

图像质量也是生成模型的基本要求 [6]，检测端改进因而需要放在完整生成配置中考察。FreeU 通过推理时调制 U-Net 主干与跳跃连接特征改善生成质量，无需重新训练模型权重 [8]。我们将这一已有技术作为生成配置开关，在沿用 HSQR 嵌入的条件下，联合分析美学评分、图文相似度与水印验证表现。FreeU 的调制规则固定，质量评分用于事后评价；G0/G1 分别在生成和反演两个阶段关闭或开启 FreeU。

具体贡献如下：

1. **残差引导的反演精修。**将 Exact-DPM 前向步修正适配于 Exact-DDIM，通过有限候选评估和逐图最佳候选保留改善 HSQR 恢复的局部去噪一致性。
2. **协方差感知的水印验证。**基于中心化正确密钥残差与 Ledoit–Wolf 协方差估计构建 Mahalanobis 评分，研究其与 Exact-DDIM 结合时的旋转验证表现及常规攻击代价。
3. **生成质量与水印验证的兼容性分析。**以配对生成样本考察 FreeU 配置的质量变化，并结合对应配置的验证结果，给出质量收益、验证表现及其权衡的系统级实证分析。

2. 相关工作

2.1 生成式水印与几何鲁棒性

Tree-Ring 在扩散初始噪声的傅里叶域嵌入环状图案 [10]。SFWMark 通过 Hermitian 对称与中心感知布局保持频域完整性，其 HSQR 变体将 QR 图案编码到实、虚分量 [5]。几何鲁棒性还依赖恢复后的空间对应关系：RingID 以离散环状模式与多通道嵌入增强密钥可分性 [1]，SynTag 通过微调解码器嵌入同步标记，并在提取前预测和校正几何失真 [2]。我们沿用 HSQR 嵌入，考察检测端数值恢复与统计评分的作用。

2.2 面向水印恢复的扩散反演

DDIM 提供常用的确定性反演路径 [9]。Exact-DPM 将反演写为隐式求解问题，采用梯度或前向步修正，并用于水印检测 [3]；GNRI 通过噪声先验引导 Newton–Raphson 迭代改善图像反演与编辑 [7]。针对失真后的水印恢复，ROAR 将起始潜变量的再生成优化与混合专家失真恢复网络结合 [12]，FARI 将单步反演与对抗 LoRA 微调结合 [11]。TAIR-WM 固定网络权重，在一阶 DDIM 路径上执行残差精修，并利用恢复特征的统计结构完成验证。

2.3 残差建模与统计验证

水印验证可采用模板距离或统计判别。SFWMark 使用 Complex-L1 [5]，Tree-Ring 在高斯零假设下推导检测 p 值 [10]，Gaussian Shading 根据匹配比特数的二项分布标定阈值 [13]。我们对扰动后的正确密钥残差拟合均值和

收缩协方差 [4]，以 Mahalanobis 距离描述残差的系统偏移、方向尺度及相关性。RingID 已讨论二元验证与多密钥识别的区别 [1]；本文将统计评分用于指定密钥验证，其结果不直接推导多密钥排序能力。

2.4 推理时特征调制与生成质量

FreeU 分析扩散 U-Net 中主干和跳跃连接特征对去噪与细节的作用，并在推理时重加权两类特征，无需重新训练模型权重 [8]。这一技术已在图像和视频生成中得到研究。SFWMark 也通过生成质量指标考察水印嵌入的影响 [5]。本文关注在 HSQR 嵌入与检测端改进并存时，FreeU 配置能否获得美学评分收益，并维持相对于对应基线的旋转验证改善。

3. 方法

3.1 问题定义与框架概述

TAIR-WM 沿用 SFWMark 的 HSQR 嵌入 [5]。给定待检测图像 x 和调用方指定的密钥 k，验证器输出该图像是否包含相应水印。多密钥识别属于候选排序任务，不作为本文的主要输出。图像依次经过 VAE 编码、扩散反演和 HSQR 特征提取：

$$z_0 = E(x), \quad \widehat{z}_T = I(z_0), \quad f = \Phi(\widehat{z}_T). \tag{1}$$

编码器 E 包含基础模型的潜变量缩放，I 将 z_0 映射为初始噪声的恢复表示 $\widehat{z}_T$，Φ 提取用于密钥验证的傅里叶特征。

在中心感知配置下，Φ 截取潜变量中央的 44×44 区域，执行移位二维 FFT，并从索引为 3 的通道选取 42×21 个复数系数。展平后记为 $c \in \mathbb{C}^m$，$m = 882$，按实部和虚部排列为

$$f = [\mathrm{Re}(c)^\top, \mathrm{Im}(c)^\top]^\top \in \mathbb{R}^p, \quad p = 2m = 1764. \tag{2}$$

模板 w_k 采用相同排列，其实部和虚部对应 QR 图案的两个半区，参考值沿用原检测器的 ±45。残差记为 $r_k = f - w_k$。图 1 给出从图像到指定密钥验证的计算流程。

3.2 残差引导的 Exact-DDIM 反演

局部重建一致性。 对于相邻扩散时刻 $t > s$，确定性 DDIM 去噪映射 $D_{t\to s}$ [9] 在噪声预测参数化下写为

$$\begin{aligned} \widehat{z}_0(z_t) &= \frac{z_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(z_t,t)}{\sqrt{\bar{\alpha}_t}}, \\ D_{t\to s}(z_t) &= \sqrt{\bar{\alpha}_s}\,\widehat{z}_0(z_t) + \sqrt{1-\bar{\alpha}_s}\,\epsilon_\theta(z_t,t). \end{aligned} \tag{3}$$

其中，ϵ_θ 为噪声预测网络，$\bar{\alpha}_t$ 和 $\bar{\alpha}_s$ 为基础调度器对应时刻的系数。反演需要寻找去噪后与当前低噪声目标 $\widetilde{z}_s$ 一致的 z_t。由于网络预测依赖这一未知变量，该过程构成隐式反演问题，普通 DDIM 反演给出的近似解未必满足去噪重建一致性。为此，以单步重建误差衡量候选质量：

$$\mathcal{L}_t(z) = \frac{1}{d}\|D_{t\to s}(z) - \widetilde{z}_s\|_2^2. \tag{4}$$

这里 d 为每幅图像的潜变量元素数。目标 $\widetilde{z}_s$ 在当前精修循环内保持固定，因此计算该损失不需要真实初始噪声。

残差引导的有限步精修。 以普通 DDIM 反演结果初始化候选，并计算其去噪结果相对于固定目标的残差：

$$z_t^{(0)} = I_{s\to t}^{\mathrm{DDIM}}(\widetilde{z}_s), \quad r_t^{(j)} = D_{t\to s}(z_t^{(j)}) - \widetilde{z}_s. \tag{5}$$

候选沿残差的反方向更新：

$$z_t^{(j+1)} = z_t^{(j)} - \eta r_t^{(j)}. \tag{6}$$

式 (6) 沿用 Exact-DPM 的前向步修正机制 [3]，并将其适配于 HSQR 检测中的一阶 DDIM 反演。该更新直接使用潜变量重建残差，无需对去噪器求导；它不同于式 (4) 的梯度下降，后者还需引入去噪映射的 Jacobian。当前配置取步长 $\eta = 0.5$，每步最多评估 $J_{\max} = 5$ 个候选，残差容差为 $\tau = 10^{-5}$，调度器的随机噪声参数设为零。

停止条件与候选保留。 精修在批内最大残差 RMS 不超过 τ，或候选评估预算耗尽时终止。采用批内最大值，使容差停止要求每幅图像均满足条件。由于残差更新不保证损失单调下降，输出不直接取最后一次更新，而是逐图像保留已评估 MSE 最小的候选：

$$j_b^\star = \arg\min_{j\in\mathcal{J}_b} \mathcal{L}_t(z_{t,b}^{(j)}), \quad \widetilde{z}_{t,b} = z_{t,b}^{(j_b^\star)}. \tag{7}$$

其中，$\mathcal{J}_b$ 为图像 b 的已评估候选集合，包含初始化；未经评估的最终更新不参与选择。只要已评估损失均为有限值，就有

$$\mathcal{L}_t(\widetilde{z}_{t,b}) \le \mathcal{L}_t(z_{t,b}^{(0)}). \tag{8}$$

所选 $\widetilde{z}_{t,b}$ 随后作为下一反演步的目标。式 (8) 约束的是单步固定目标下的局部损失，不保证严格改善、全局收敛或恢复旋转中丢失的信息；Exact-DDIM 在此表示所采用的精修方法类别，不表示有限预算下的精确恢复。完整的候选评估与验证决策见算法 1。

3.3 协方差感知的水印验证

局部去噪一致性约束了反演候选，但恢复后的水印特征仍可能偏离密钥模板。此类偏差既可能包含系统偏移，也可能在多个频率位置及实部、虚部之间共同变化。验证因此以正确密钥下的特征残差为建模对象，使评分反映这些偏差的尺度与相关性。

对拟合特征 f_i 及其已知正确模板 w_{k_i}，定义 $r_i = f_i - w_{k_i}$，并估计残差均值与协方差：

$$\widehat{\mu} = \frac{1}{n}\sum_{i=1}^{n} r_i, \quad S = \frac{1}{n}\sum_{i=1}^{n}(r_i - \widehat{\mu})(r_i - \widehat{\mu})^\top. \tag{9}$$

均值 $\widehat{\mu}$ 描述恢复特征相对于模板的系统偏移，S 描述不同残差分量的变化及相关性。拟合样本数 $n = 1024$ 小于特征维度 $p = 1764$，样本协方差因而秩亏。采用 Ledoit–Wolf 收缩 [4] 获得用于评分的协方差：

$$\begin{aligned} \widehat{\Sigma} &= (1-\lambda)S + \lambda a I, \quad a = \frac{\mathrm{tr}(S)}{p}, \\ \Sigma_{\mathrm{reg}} &= \widehat{\Sigma} + \varepsilon I. \end{aligned} \tag{10}$$

收缩系数 λ 由拟合数据确定，非负抖动 ε 仅在 Cholesky 分解需要时加入。统计量针对正确密钥残差拟合，并按反演配置分别估计。

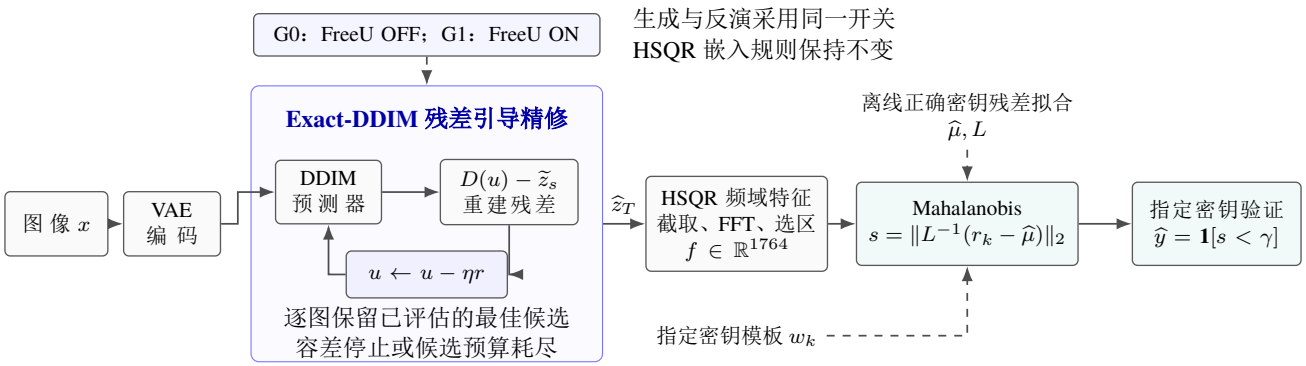


图 1. TAIR-WM 验证流程。Exact-DDIM 精修恢复潜变量，HSQR 频域特征经中心化与协方差白化后完成指定密钥验证。实线为检测数据流，虚线为配置、模板或离线统计量。FreeU 在生成和反演阶段采用匹配的 ON/OFF 配置，质量评分不参与反演更新或验证决策。

将 Σ_{reg} 分解为 $LL^\top$ 后，通过三角方程 $Lv_k = r_k - \widehat{\mu}$ 对中心化残差进行白化，得到 Mahalanobis 评分：

$$s_{\text{Mah}}(r_k) = \|v_k\|_2 = \sqrt{(r_k - \widehat{\mu})^\top \Sigma_{\text{reg}}^{-1}(r_k - \widehat{\mu})}. \tag{11}$$

式 (11) 给出等价的距离形式，实现中使用三角求解而不显式构造逆矩阵。该评分降低高方差方向的权重，并通过非对角项考虑相关偏移，从而衡量观测残差与拟合正确密钥群体的兼容程度；不要求为水印与无水印图像建立完整的高斯似然模型。

协方差权重依据拟合分布中的重复扰动确定，其作用也受该分布约束。满秩白化本身可逆，后续范数才将残差向量压缩为标量。因此，密钥区分能力可能发生的变化与方向权重有关，不能解释为已经证明某些高频系数被删除。因此，该距离的统计含义是对指定密钥残差分布的兼容性评价。

作为对照，原检测器的 Complex-L1 对复数系数 c_j 及模板系数 $u_{k,j}$ 计算

$$s_{\text{CL1}}(f, w_k) = \frac{1}{m}\sum_{j=1}^{m} |c_j - u_{k,j}|, \qquad |a + ib| = \sqrt{a^2 + b^2}. \tag{12}$$

它对复数差的模长取均值，不单独累加实、虚部的绝对差。Mahalanobis 则用式 (11) 评价中心化残差，最终输出

$$\widehat{y} = \mathbf{1}[s_{\text{Mah}}(f - w_k) < \gamma]. \tag{13}$$

阈值 γ 由独立干净无水印校准集的距离顺序统计量确定：对每个反演配置与距离，取 2,000 个校准距离的第 20 小值，以严格小于该值判阳性，并将阈值冻结用于所有测试条件。这个经验校准规则与测试 ROC 上的低假阳性率性能是两种评价协议。均值、收缩协方差及阈值均为离线参数估计，扩散模型权重保持固定。

3.4 FreeU 与水印验证的兼容性设置

FreeU [8] 在 U-Net 解码阶段调制主干和跳跃连接特征。我们采用已有实现，将其作为固定的推理时配置：G0 在生成与反演阶段关闭 FreeU，G1 在两个阶段均开启。开关改变 U-Net 的特征计算，HSQR 的嵌入位置、符号规则和检测模板保持一致；Exact-DDIM 的残差目标、更新与候选选择仍分别由式 (4)–(7) 定义，去噪映射 D 使用相应配置下的网络计算。

算法 1 Exact-DDIM 与协方差感知的指定密钥验证

输入： 图像 x、指定密钥 k、匹配的反演配置、统计量 $(\widehat{\mu}, L)$、阈值 γ

$z \leftarrow E(x)$
循环 按噪声递增顺序遍历反演步 (s, t) **执行**
  $\widetilde{z}_s \leftarrow z$；$u \leftarrow I_{s\to t}^{\text{DDIM}}(\widetilde{z}_s)$
  对每幅图像 b，令 $e_b^\star \leftarrow +\infty$
  循环 $j = 0, \ldots, J_{\max} - 1$ **执行**
    $r \leftarrow D_{t\to s}(u) - \widetilde{z}_s$
    对每个 b，计算 $e_b \leftarrow \text{mean}(r_b^2)$
    对满足 $e_b < e_b^\star$ 的图像 b：
      $u_b^\star \leftarrow u_b$；$e_b^\star \leftarrow e_b$
    若 $\max_b \sqrt{e_b} \le \tau$ **则**
      跳出循环
    结束条件
    $u \leftarrow u - \eta r$
  结束循环
  $z \leftarrow u^\star$
结束循环
$f \leftarrow \Phi(z)$；解三角方程 $Lv = f - w_k - \widehat{\mu}$
返回 $\mathbf{1}[\|v\|_2 < \gamma]$

两组生成使用配对的提示词、初始潜变量种子与密钥，同一生成池内不同反演器复用图像。质量评价直接作用于保存的生成图像，不经过后续反演；验证评价则将这些图像施加攻击，再通过图 1 的流程恢复和判别。由此，可以考察含水印生成是否获得美学评分收益，以及对应配置下的反演与统计验证组合是否继续改善旋转验证。G0/G1 的验证差异同时涉及生成与反演阶段，不能单独归因于生成端调制。

兼容性分析联合使用质量指标与验证指标，考察二者的收益和代价。FreeU 的系数固定，图像质量分数用于事后评测；整个流程无需质量反馈门控或水印驱动的特征调节。算法 1 给出指定密钥验证过程。

参考文献

[1] Hai Ci, Pei Yang, Yiren Song, and Mike Zheng Shou. RingID: Rethinking tree-ring watermarking for enhanced multi-key identification. In *ECCV*, pages 338–354, 2024.

[2] Han Fang, Kejiang Chen, Zehua Ma, Jiajun Deng, Yicong Li, Weiming Zhang, and Ee-Chien Chang. SynTag: Enhancing the geometric robustness of inversion-based generative image watermarking. In *ICCV*, pages 15416–15425, 2025.

[3] Seongmin Hong, Kyeonghyun Lee, Suh Yoon Jeon, Hyewon Bae, and Se Young Chun. On exact inversion of DPM-solvers. In *CVPR*, pages 7069–7078, 2024.

[4] Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004.

[5] Sung Ju Lee and Nam Ik Cho. Semantic watermarking reinvented: Enhancing robustness and generation quality with Fourier integrity. In *ICCV*, pages 18759–18769, 2025.

[6] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *CVPR*, pages 10684–10695, 2022.

[7] Dvir Samuel, Barak Meiri, Haggai Maron, Yoad Tewel, Nir Darshan, Shai Avidan, Gal Chechik, and Rami Ben-Ari. Lightning-fast image inversion and editing for text-to-image diffusion models. In *ICLR*, 2025.

[8] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. FreeU: Free lunch in diffusion U-Net. In *CVPR*, pages 4733–4743, 2024.

[9] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *ICLR*, 2021.

[10] Yuxin Wen, John Kirchenbauer, Jonas Geiping, and Tom Goldstein. Tree-rings watermarks: Invisible fingerprints for diffusion images. In *NeurIPS*, pages 58047–58063, 2023.

[11] Jindong Yang, Han Fang, Weiming Zhang, Nenghai Yu, and Kejiang Chen. FARI: Robust one-step inversion for watermarking in diffusion models. In *ICLR*, 2026.

[12] Hanyi Wang, Han Fang, Shi-Lin Wang, and Ee-Chien Chang. ROAR: Reducing Inversion Error in Generative Image Watermarking. In *ICCV*, pages 19742–19751, 2025.

[13] Zijin Yang, Kai Zeng, Kejiang Chen, Han Fang, Weiming Zhang, and Nenghai Yu. Gaussian Shading: Provable Performance-Lossless Image Watermarking for Diffusion Models. In *CVPR*, pages 12162–12171, 2024.